

Computational Linguistics

Corpus Development

Quy Nguyen

Nội dung

1. Tầm quan trọng của corpora
2. Đặc điểm của corpus
3. Quy trình đảm bảo chất lượng corpus
4. Vietnamese constituency treebank

Định nghĩa corpus (pl: corpora)

- ▶ Sinclair's (1996) definition:
A corpus is a collection of pieces of language that are selected and ordered according to explicit linguistic criteria in order to be used as a sample of the language.

Tầm quan trọng của electronic corpora

Corpora được sử dụng:

- ▶ Nhà ngôn ngữ học: rút trích ví dụ, nghiên cứu các hiện tượng ngôn ngữ
- ▶ Nhà từ điển học: lấy ví dụ cho ngữ cảnh sử dụng của từ
- ▶ Là tài liệu hướng dẫn cho người dạy/học ngôn ngữ
- ▶ Là training data cho các NLP applications:
 - ▶ hệ thống nhận diện tiếng nói, hệ thống phân tích cú pháp, dịch máy, ...

“Chúng ta phải hiểu mình đang cần gì và phát triển corpus đáp ứng yêu cầu đó.”

Đặc điểm của corpus

- ▶ Corpus usually implies the following characteristics:
 - ▶ machine-readable (i.e., computer-based)
 - ▶ authentic (i.e., naturally occurring)
 - ▶ finite size
 - ▶ sampled (bits of text taken from multiple sources)
 - ▶ representative of a particular language or language variety

Sampling in corpus creation

- ▶ Có thể xem corpus như một mẫu đại diện cho một ngôn ngữ
- ▶ Ngôn ngữ vô hạn, nhưng corpus phải giới hạn kích thước
- ▶ Mục tiêu của lấy mẫu là để giới hạn kích thước corpus, tuy nhiên, vẫn đảm bảo được các đặc điểm ngôn ngữ, sự đa dạng của ngôn ngữ (language variety).
- ▶ Một vài yếu tố cần xem xét khi lấy mẫu:
 - ▶ Thể loại texts: spoken, fiction, magazines, newspapers, or academic, ...
 - ▶ Số lượng texts
 - ▶ Chọn text samples
 - ▶ Chiều dài text samples
 - ▶ ...

Một vài yếu tố cần xem xét khi lấy mẫu

- ▶ Data được thu thập từ **nhiều nguồn** khác nhau để có thể làm mẫu được
Ví dụ: British National Corpus (BNC) gồm nhiều thể loại (e.g. spoken, fiction, magazines, newspapers, and academic).
- ▶ Data phải **cân bằng**
- ▶ Các mẫu ngôn ngữ thuộc **cùng một khoảng thời gian** nhất định
Ví dụ: BNC gồm các texts từ **1960-1993**

Tiếng Việt có thay đổi theo thời gian?

Representativeness

- ▶ Representativeness refers to the extent to which a sample includes the full range of variability in a population (Biber 1993)
- ▶ Representativeness is a fluid concept closely related to your research questions
 - ▶ If you want a corpus which is representative of general English, a corpus representative of newspapers will not do

Finite size

- ▶ Thông thường, corpora có kích thước cố định.
Ví dụ: BNC contains **100 million words**
- ▶ Một vài kho dữ liệu luôn tăng kích thước (them data mới): có thể update hiện tượng ngôn ngữ theo thời gian, ...
- ▶ Tuy nhiên:
 - ▶ Tính sampling and representativity khó đảm bảo
 - ▶ Tăng kích thước → tăng thời gian huấn luyện, ...

Quy trình phát triển corpus

- ▶ Thu thập raw text
- ▶ Phát triển guidelines
- ▶ Phát triển annotation tool và các tool tiền xử lý
- ▶ Huấn luyện annotator
- ▶ Markup Annotation
- ▶ Kiểm tra chéo
- ▶ Cleaning up corpus
- ▶ Công bố corpus và guideline

Quy trình phát triển corpus

