

Computational Linguistics

Introduction

Quy Nguyen

Nội dung

1. Giới thiệu Ngôn ngữ học máy tính (Computational linguistics)
2. Tri thức ngôn ngữ (linguistic knowledge)
3. Một vài ứng dụng CL/NLP
4. Nội dung môn học
5. Đánh giá môn học
6. Tài liệu tham khảo

Computational linguistics (CL) vs Natural language processing (NLP)

- ▶ Cả hai lĩnh vực đều nhằm mục tiêu giúp máy tính có thể hiểu ngôn ngữ như con người.
- ▶ *Computational linguistics* khám phá tri thức ngôn ngữ (linguistics).
 - ▶ Computational linguists có tri thức ngôn ngữ
 - ▶ Computational linguists nghiên cứu các mô hình toán học hiệu quả trong việc học, lĩnh hội các hiện tượng ngôn ngữ.
- ▶ *NLP* tập trung vào các yếu tố kỹ thuật (Khoa học máy tính).
 - ▶ Người nghiên cứu NLP cho rằng học không nhất thiết có nhiều tri thức về ngôn ngữ.
 - ▶ Áp dụng các mô hình toán học để phân tích ngôn ngữ.
 - ▶ Nếu mô hình chưa cho kết quả thực thi tốt thì tiến hành phân tích lỗi để cải tiến mô hình.

Computational linguistics

CL khai thác đặc trưng ngôn ngữ, tri thức ngôn ngữ dựa trên loại hình ngôn ngữ, lịch sử hình thành của ngôn ngữ, yếu tố xã hội ảnh hưởng ngôn ngữ, yếu tố tâm lý ảnh hưởng ngôn ngữ, ...


- ▶ *Ngôn ngữ đơn lập* (tiếng Hán, tiếng Thái, tiếng Việt, ...)
 - ▶ Từ không biến đổi hình thái.
 - ▶ Từ không mặc nhiên phân biệt bởi khoảng trắng.
- ▶ *Ngôn ngữ hòa kết* (tiếng Anh, tiếng Nga, tiếng Pháp, ...)
 - ▶ Từ biến đổi hình thái.
 - ▶ Từ được phân biệt bởi khoảng trắng.

Tại sao cần tri thức ngôn ngữ?

Phân tích nghĩa của các câu sau? Cần tri thức ngôn ngữ gì để hiểu đúng nghĩa của các câu này?

1. học sinh học sinh học
2. cổ đeo vòng cổ
3. ông già đi nhanh
4. Nam kể về tai nạn hôm qua

Các mức độ của Tri thức ngôn ngữ



Một số bài toán Khai thác tri thức ngôn ngữ

A complex language behavior requires various kinds of knowledge of language:

- ▶ Phonetics and Phonology analysis — knowledge about linguistic sounds
- ▶ Text normalization
 - ▶ Stemming
 - ▶ Lemmatization
- ▶ Text segmentation
 - ▶ Sentence segmentation
 - ▶ Word segmentation (Vietnamese)
- ▶ Gán nhãn chuỗi
 - ▶ Từ loại (Part-of-speech (POS) tagging)
 - ▶ Thực thể tên riêng (Name Entity Recognition)
- ▶ Phân tích cú pháp
 - ▶ Constituency parsing
 - ▶ Dependency parsing
 - ▶ ...
- ▶ Phân tích ngữ nghĩa (semantic roles)
- ▶ Phân tích Pragmatics/Discourse

Một số ứng dụng CL/NLP

- ▶ Text classification (Sentiment analysis)
- ▶ Machine translation
- ▶ Question and answering
- ▶ Speech recognition systems
- ▶ Text-to-speech synthesizers
- ▶ Web search engines
- ▶ Text editors (Grammar checking)
- ▶ Language instruction
- ▶ Text summarization
- ▶ Text generation (Image Captioning)

Text normalization

- ▶ Text Normalization, such as stemming and lemmatization:
The goal of both stemming and lemmatization is to reduce inflectional forms and sometimes derivationally related forms of a word to a common base form.
 - ▶ **Stemming** algorithms usually refer to a *heuristic process*, work by cutting off the end or the beginning of the word.
studies -> *studi*
studying -> *study*
 - ▶ **Lemmatization**, on the other hand, takes into consideration the morphological analysis of the words. *studies* -> *study*
studying -> *study*
 - ▶ Text normalization is frequently used when converting text to speech, used for searching, etc.

Sentence segmentation

- ▶ Ví dụ: Cho đoạn văn bản sau:

"Cách bờ biển khoảng 10,5 km, TP Huế, tỉnh Thừa Thiên Huế, được xem là thành phố xanh với hơn 65.000 cây xanh đường phố, công viên. Bão Noul đã làm hơn 10.000 cây gãy đổ, nhiều nhất từ xưa đến nay. Một số công viên dọc bờ sông Hương như Thương Bạc, Phú Xuân, Bến Me, Kim Long..., nhiều cây cổ thụ nằm ngổn ngang trên mặt đất."

Kết quả sau khi tách câu:

<s> Cách bờ biển khoảng 10 km, TP Huế, tỉnh Thừa Thiên Huế, được xem là thành phố xanh với hơn 65.000 cây xanh đường phố, công viên. </s>

<s> Bão Noul đã làm hơn 10.000 cây gãy đổ, nhiều nhất từ xưa đến nay. </s>

<s> Một số công viên dọc bờ sông Hương như Thương Bạc, Phú Xuân, Bến Me, Kim Long..., nhiều cây cổ thụ nằm ngổn ngang trên mặt đất. </s>

- ▶ Thách thức: *Nhập nhầm dấu câu*

Word Segmentation

- ▶ **Tách từ** là thao tác chia văn bản thành những đơn vị từ.
- ▶ Ví dụ: Có câu sau:

<s>

Hắn đã lập gia đình, nhưng cái gia đình ấy đã tan vỡ.

</s>

Kết quả sau khi tách từ:

<s>

Hắn đã lập gia_đình , nhưng cái gia_đình ấy đã tan_vỡ .

</s>

Hoặc có thể trình bày kết quả tách từ dưới dạng:

<s>

*Hắn/B đã/B lập/B gia/B đình/I ,/B nhưng/B cái/B gia/B
đình/I ấy/B đã/B tan/B vỡ/I ./B*

</s>

Part-of-speed tagging

- ▶ **"Part-of-speech (POS)**, also called grammatical tagging is the process of marking up a word in a text (corpus) as corresponding to a particular part of speech, based on both its definition and its context."¹

- ▶ Ví dụ: Có câu sau:

*<s> Hấn đã lập gia đình, nhưng cái gia đình ấy đã tan vỡ.
</s>*

Kết quả sau khi tách từ:

*<s> Hấn đã lập gia_đình , nhưng cái gia_đình ấy đã tan_ vỡ
. </s>*

Kết quả sau khi gán nhãn từ loại:

*<s> Hấn/Pp đã/R lập/Vv gia_đình/Nn ,/PU nhưng/Cp
cái/M gia_đình/Nn ấy/Pd đã/R tan_ vỡ/Vv ./PU </s>*

¹https://en.wikipedia.org/wiki/Part-of-speech_tagging

Named-entity recognition

- ▶ "Named-entity recognition (NER) (also known as (named) entity identification, entity chunking, and entity extraction) is a subtask of information extraction that seeks to locate and classify named entities mentioned in unstructured text into pre-defined categories such as person names, organizations, locations, medical codes, time expressions, quantities, monetary values, percentages, etc."²

²https://en.wikipedia.org/wiki/Named-entity_recognition


Named-entity recognition

► Ví dụ:

Theo thống kê của `<ENAMEX TYPE="ORGANIZATION">Sở y tế <ENAMEX TYPE="LOCATION">Hà Nội</ENAMEX></ENAMEX>`, trong năm 2017 vừa qua có đến hơn 100.000 ca mắc bệnh sốt xuất huyết. Không chỉ sốt xuất huyết, rất nhiều dịch bệnh nguy hiểm khác bùng phát cũng do các côn trùng gây hại như bệnh dịch hạch, bệnh não... Theo Bách khoa tự điển `<ENAMEX TYPE="LOCATION">Anh Quốc</ENAMEX>` “Hầu hết các bệnh sốt nặng ở người đều do vi-rút truyền từ côn trùng gây ra”.

Constituency parsing

► A Vietnamese constituency tree




Constituency parsing

- ▶ A Vietnamese constituency tree based on the Penn Treebank format

```
<s>
(S
  (S
    (NP-SBJ (Pp-H Hấn))
    (VP (R đã) (Vv-H lập)
      (NP-CMP (Nn-H gia_đình))))
  (PU ,)
  (Cp nhưng)
  (S
    (NP-SBJ (M cái) (Nn-H gia_đình) (Pd ấy))
    (VP (R đã) (Vv-H tan_vỡ)))
  (PU .))|
</s>
```

Dependency parsing


Các nhãn trình bày sự phụ thuộc ngữ pháp giữa các từ trong câu



1	Tùng	_ N Np _	2	SUB	_ _
2	nói	_ V V _	0	ROOT	_ _
3	không	_ R R _	4	ADV	_ _
4	nên	_ V V _	2	DOB	_ _
5	vội vàng	_ A A _	4	VMOD	_ _
6	mà	_ C C _	4	COORD	_ _
7	mẹ	_ N N _	4	SUB	_ _
8	phải	_ V V _	6	CONJ	_ _
9	âm thầm	_ A A _	10	VMOD	_ _
10	tìm hiểu	_ V V _	8	VMOD	_ _
11	.	_ . _	2	PUNCT	_ _

Semantic role labling

- Vai trò ngữ nghĩa là mối quan hệ giữa các thành phần cú pháp với vị ngữ (động từ chính)
Ví dụ: *Agent* (tác thể), *Patient* (bị thể), *Instrument* (công cụ), *Locative* (vị trí), *Temporal* (thời gian), *Manner* (cách thức), *Cause* (nguyên nhân), . . .



Semantic role labling

- ▶ SRL rất hữu ích trong trong hỏi đáp. Nó giúp máy tính hiểu câu ở mức độ ngữ nghĩa nông, và có thể trả lời một số dạng câu hỏi

Ví dụ:

Ai đã đánh **Scott** bằng **một quả bóng chày**?

Ai là người đã bị **Kristina** đánh bằng **một quả bóng chày**?

Kristina đã đánh **Scott** bằng **cái gì**?

Kristina đã đánh **Scott** bằng **một quả bóng chày** **khi nào**?

Time Annotation

- ▶ Biểu thức thời gian cho chúng ta biết:
 - ▶ Khi nào vấn đề xảy ra
 - ▶ Vấn đề xảy ra trong bao lâu
 - ▶ Vấn đề có xảy ra thường xuyên không

Ví dụ:

- ▶ He wrapped up a **three-hour** meeting with the Iraqi president in Baghdad **today**.
- ▶ The king lived **4,000 years ago**.
- ▶ I'm a creature of **the 1960s, the days of free love**.

Error Tagging

- ▶ Error tagging thường được làm cho các kho ngữ liệu dành cho người học
 - ▶ Cambridge Learner Corpora (CLC) and the Longman Learner's Corpus
- ▶ Các kiểu lỗi được sử dụng trong CLC
 - ▶ sử dụng sai từ
 - ▶ thiếu một cái gì đó
 - ▶ từ / cụm từ cần thay thế
 - ▶ từ / cụm từ không cần thiết

Ví dụ:

*My friend told me if I knew about Shakespeare. But, <TIP
id=17-56 etype=24 tutor="I knew">I know</TIP>*

Error Tagging

- Error tagging example:

```
<A>And, please describe this picture.</A>
<B>Describe? <F>Mhm</F>. <.></.> Maybe, <SC>this</SC>
<SC>toda</SC> <F>mm</F> it is a sunny day, and
<JP><F>unto</F></JP> in front of <SC?>hou</SC?>
<at odr="1" crr="a"></at> big house, <F>er</F> two
<n_inf odr="2" crr="housewives">housewives</n_inf>
<v_agr odr="3" crr="are">is</v_agr> talking
<prp_lxc2 odr="4" crr="to"></prp_lxc2> each other.
```

<at odr="1" crr="a"> (article, order of correction, correct form)

Pragmatics vs discourse

- ▶ Pragmatics studies the ways **in which context contributes to meaning**
- ▶ Discourse analysis looks how the sentences are glued together

Ex:

- ▶ Speaker 1: *would you like to go for a drink?*
- ▶ Speaker 2: *great! what time?*

The discourse analysis would be looking at how this communicative event works mechanically whereas the pragmatist would be looking at underlying (implicit) meanings (in this case 'drink' means trip to the pub, for example).

Discourse Analysis

- ▶ Giúp cho máy có thể hiểu các hiện tượng diễn ngôn (discourse phenomena), được ứng dụng trong question answering, summarization, machine translation, generation, ...
- ▶ Chú thích mối liên kết (relation) giữa các cặp câu đứng liên kề nhau trong đoạn văn (văn bản)
 - ▶ Explicit connectives
 - ▶ Implicit connectives
 - ▶ AltLex, EntRel, NoRel

Discourse Analysis

1. The city's Campaign Finance Board has refused to pay Mr. Dinkins \$95,142 in matching funds because his campaign records are incomplete. (0041)

Ban Tài chính Chiến dịch của Thành phố đã từ chối chi trả phí bù trừ \$95.142 cho ông Dinkins bởi vì hồ sơ chiến dịch của ông ấy chưa hoàn chỉnh.

2. Motorola is fighting back against junk mail. *So much of the stuff poured into its Austin, Texas, offices that its mail rooms there simply stopped delivering it.* Implicit = so **Now, thousands of mailers, catalogs and sales pitches go straight into the trash.** (0989)

Motorola đang chiến đấu chống thư rác. Quá nhiều thứ đổ vào các văn phòng của họ ở Austin, Texas đến nỗi mà phòng xử lý thư từ chỉ đơn giản là ngừng phân phát chúng. Implicit = so Hiện tại, hàng ngàn bưu phẩm, catalogs, sự chào hàng bị chuyển thẳng vào sọt rác.

Coreference resolution

Coreference resolution is the task of finding all expressions that refer to the same entity in a text. It is an important step for a lot of higher level NLP tasks that involve natural language understanding such as document summarization, question answering, and information extraction.

Ex:

- ▶ *How many states were in the United States that year?*

Sentiment analysis

Gán nhãn aspect-sentiment cho chủ đề Khách Sạn

- ▶ Phân loại cảm xúc (opinion polarity): positive, negative, neutral
- ▶ Aspect: gồm bộ entity-attribute

Ví dụ:

Phòng ốc rộng rãi và thoáng. Nhân viên phục vụ rất tận tình, chu đáo. Nói chung là ok. Nếu đưa ra khuyết điểm thì có lẽ là lỗi đi vào buổi tối hơi khó vì gần parking.



- ▶ ROOMSDESIGNFEATURES: positive
- ▶ ROOMSCOMFORT: positive
- ▶ SERVICESGENERAL: positive
- ▶ HOTELGENERAL: positive
- ▶ HOTEL MISCELLANEOUS: negative

Tại sao NLP khó?

- ▶ Sự phức tạp/nhập nhằng trong việc sử dụng ngôn ngữ
- ▶ Ví dụ:
 - ▶ Đảo trật tự từ có thể tạo ra câu có nghĩa khác nhau:
 - ▶ Con mèo *này trắng*
 - ▶ Con mèo *trắng này*
 - ▶ Đảo trật tự từ không làm thay đổi nghĩa của câu:
 - ▶ *Khuyết điểm này* tôi đang cố khắc phục.
 - ▶ Tôi đang cố khắc phục *khuyết điểm này*.
 - ▶ Một câu có thể hiểu theo nhiều nghĩa
 - ▶ Nam kể về *tai nạn hôm qua*.
 - ▶ Nam *kể* về tai nạn *hôm qua*.
 - ▶ Cô ấy đang *bơi*. {to swim}
 - ▶ Cô ấy đang *bơi*. {to struggle with one's job}

Disambiguate

► Phân tích cú pháp



Disambiguate

- ▶ Part-of-speech tagging:
 - ▶ *Cô²/Pp đẹp quá.*
→ cô² = she
 - ▶ *Cô²/Nn dài quá.*
→ cô² = neck
- ▶ Word sense disambiguation:
 - ▶ Tin học: *memory* = *bộ nhớ*
 - ▶ Y khoa: *memory* = *trí nhớ*

Yêu cầu

Có kiến thức về:

- ▶ Ngôn ngữ học
- ▶ Python
- ▶ Giải tích, đại số tuyến tính, xác suất thống kê
- ▶ Máy học

Nội dung môn học

1. Corpus development
2. Text classification
 - ▶ Sentiment analysis using Naive Bayes
 - ▶ Sentiment analysis using Logistic regression
 - ▶ Neural networks in NLP
3. Language modeling
 - ▶ N-gram model
 - ▶ Recurrent neural network
4. Word embedding, attention and transformers
5. Sequence labeling problems
 - ▶ POS tagging/NER using CRF
6. Constituency/dependency parsing

Đánh giá môn học

1. 50% đồ án
 - ▶ Xây dựng một NLP system
 - ▶ Slides, thuyết trình
2. 50% thi lý thuyết cuối kỳ

Tài liệu tham khảo

- ▶ Daniel Jurafsky and James Martin, 2020, *Speech and Language Processing* (3rd edition).
- ▶ Jacob Eisenstein, 2018, *Natural Language Processing*.

Xử lý ngôn ngữ tự nhiên và các vấn đề liên quan



- ▶ Xử lý ngôn ngữ tự nhiên là sự giao thoa giữa:
 - ▶ Ngôn ngữ học (linguistics)
 - ▶ Máy học (machine learning)
 - ▶ Trí tuệ nhân tạo (AI)
 - ▶ Khoa học máy tính (computer science)

Ngôn ngữ học

- ▶ Mục tiêu của **ngôn ngữ học**: Tìm hiểu cách thức ngôn ngữ được vận hành, ví dụ như:
 - ▶ Ngôn ngữ thuộc họ nào, loại hình nào, các họ ngôn ngữ có liên quan với nhau như thế nào?
 - ▶ Tiêu chí để xác định một câu đúng ngữ pháp là gì? Chúng ta có thể áp dụng các tiêu chí này trên nhiều ngôn ngữ khác nhau hay không?
 - ▶ Ngôn ngữ thay đổi như thế nào và tại sao phải thay đổi?
 - ▶ Con người học ngôn ngữ đầu tiên của họ như thế nào và có gì khác khi họ học ngôn ngữ thứ 2?
- ▶ **NLP** tận dụng sự hiểu biết từ ngôn ngữ học để xây dựng các kỹ thuật ngôn ngữ.

Ảnh hưởng của ngôn ngữ học đối với NLP

- ▶ Tiếng Việt thuộc ngữ hệ Đông Nam Á (Austroasiatic languages), nhánh Mon-Khmer, loại hình đơn lập
- ▶ Tiếng Anh thuộc ngữ hệ Ấn-Âu (Indo-European languages), loại hình hòa kết
- ▶ Đặc điểm ngôn ngữ ảnh hưởng việc xử lý ngôn ngữ, ví dụ
 - ▶ Tiếng Anh có biến cách, từ được phân biệt bằng khoảng trắng
 - ▶ Stemming, lemmatization
 - ▶ POS tags được thiết kế dựa trên word forms, ví dụ:
PRP: Personal pronoun (I, you, ...)
PRP\$: Possessive pronoun (mine, yours, ...)
 - ▶ Tiếng Việt không có biến cách, từ không được phân biệt bởi khoảng trắng
 - ▶ Word segmentation
 - ▶ POS tags được thiết kế dựa trên khả năng nét hợp và chức năng cú pháp của từ, ví dụ:



Máy học

- ▶ Machine learning (ML) is the scientific [study of algorithms](#) and statistical models that computer systems use to perform a specific task without using explicit instructions, relying on patterns and inference instead. Machine learning algorithms build a mathematical model based on sample data, known as "training data", in order to make predictions or decisions without being explicitly programmed to perform the task.³
 - ▶ Hầu hết các ứng dụng NLP đạt kết quả tốt hiện nay đều sử dụng máy học bởi vì ngôn ngữ rất phức tạp
 - ▶ Ví dụ: Hệ thống dịch máy được xây dựng dựa trên kho ngữ liệu song ngữ, không phải dựa trên luật hay từ điển.
- ▶ Vì vậy, có nền tảng về máy học là yêu cầu thiết yếu của khóa học NLP

³https://en.wikipedia.org/wiki/Machine_learning

Trí tuệ nhân tạo (AI)

- ▶ In computer science, artificial intelligence (AI), sometimes called machine intelligence, is intelligence demonstrated by machines, in contrast to the natural intelligence displayed by humans.⁴
- ▶ Mục tiêu của AI là tự động hóa tiềm năng trí tuệ của con người
 - ▶ Ngôn ngữ là một khía cạnh nền tảng của trí thông minh con người
 - ▶ Ngôn ngữ có ích trong việc giải quyết các nút thắt về tri thức, cung cấp kiến thức cho hệ thống AI để nó có thể đưa ra những kết luận hữu ích
 - ▶ Suy luận cũng cần thiết cho việc hiểu ngôn ngữ
 - a. *The trophy doesn't fit in the suitcase because it is too **big**.*
 - b. *The trophy doesn't fit in the suitcase because it is too **small**.*

⁴https://en.wikipedia.org/wiki/Artificial_intelligence

- ▶ "A computer scientist studies the theory of computation and the practice of designing software systems"⁵
 - ▶ "The theory of computation is the branch that deals with how efficiently problems can be solved on a model of computation, using an algorithm."

⁵https://en.wikipedia.org/wiki/Computer_science

Khoa học máy tính

- ▶ NLP thể hiện một vài khía cạnh cốt lõi của khoa học máy tính
 - ▶ Ngôn ngữ tự nhiên có thể được mô hình hóa sử dụng lý thuyết ngôn ngữ hình thức (formal language theory), tương tự như lý thuyết được sử dụng để phân tích ngôn ngữ lập trình
Ex: Let $\Sigma = \{a, b, c, \dots, y, z\}$. Then Σ^* is the set of all strings over the Latin alphabet.
 - ▶ Dữ liệu ngôn ngữ tự nhiên cũng yêu cầu các thuật toán hiệu quả, có thể phân tích độ phức tạp về không gian và thời gian thực thi.
 - ▶ Các thuật toán này phải được thực thi trên các kiến trúc đa dạng, chẳng hạn như các hệ thống phân tán, GPU, hoặc các thiết bị mobile.